

# 生産管理 中間レポート

中央大学理工学部  
ビジネスデータサイエンス学科  
23D7104001I 高木悠人

---

## 1. 実行環境

本課題では、以下の環境で実行・分析した。

|                |                                          |
|----------------|------------------------------------------|
| PC (notebook): | Apple macbook air m4                     |
| Python 環境:     | venv 仮想環境(ローカルでの実行)                      |
| Python バージョン:  | python-3.13.9                            |
| 各種パッケージバージョン:  | requirements.txt リンクは付録の項に示すこととした        |
| セッション管理:       | Python Package(SessionSmith==2.0.0)を利用した |
| コードバージョン管理:    | GitHub(リンクは付録の項に示すこととした)                 |

## 2. 課題 1

### (ア) 課題概要

SKAB データについて XGBoost を用いてモデル構築を行い、RandomForest の変数重要度、SHAP 値と比較してどのような違いがあるか検証を行え。また、可能であれば SVM など他の予測モデルで予測を行った結果と比較を行い、予測に効く変数が検討したモデルでどのように異なるか考察を行え。

### (イ) 分析方針

本分析は、以下の手順で実施した。

#### ① SKAB データの取得と加工

GitHub から csv 形式で保存されているデータを取得し、縦方向に結合する。今回利用したデータは、SKAB の GitHub リポジトリ(付録の項にリンクを示す)から取得した。表形式のデータから、分析に利用しない datetime 列と changepoint 列を削除する。

#### ② データの分割

本分析では、SKAB データを用いた特徴量重要度および SHAP 値の比較を目的としている。

#### ③ XGBoost, RandomForest, SVM モデルを構築する

各モデルを構築する。

#### ④ 各モデルの SHAP 値や変数重要度を比較する

SVM の重要度は Permutation Importance で算出する。そして、RF は不純度減少、XGB は gain、SVM は Permutation であり定義が異なるため、順位中心に比較する

(ウ) 分析結果

はじめに、データの概要を以下に示す。まず、基本統計量を算出した。

表 1. データの基本統計量

|                     | count  | mean       | std       | min        | 25%        | 50%        | 75%        | max        |
|---------------------|--------|------------|-----------|------------|------------|------------|------------|------------|
| Accelerometer1RMS   | 3367.0 | 0.026755   | 0.000371  | 0.025553   | 0.026506   | 0.026760   | 0.027019   | 0.027946   |
| Accelerometer2RMS   | 3367.0 | 0.040155   | 0.000904  | 0.037474   | 0.039537   | 0.040147   | 0.040734   | 0.053439   |
| Current             | 3367.0 | 0.985841   | 0.274451  | 0.375488   | 0.750555   | 1.011110   | 1.210285   | 1.662610   |
| Pressure            | 3367.0 | 0.081592   | 0.249812  | -0.929070  | 0.054711   | 0.054711   | 0.382638   | 1.038490   |
| Temperature         | 3367.0 | 74.330020  | 2.765793  | 69.243100  | 72.100000  | 73.950700  | 75.864000  | 79.889100  |
| Thermocouple        | 3367.0 | 25.755188  | 0.178642  | 25.457200  | 25.609500  | 25.750400  | 25.885400  | 26.104400  |
| Voltage             | 3367.0 | 231.091404 | 10.650518 | 203.725000 | 225.411500 | 231.259000 | 236.951500 | 255.324000 |
| Volume Flow RateRMS | 3367.0 | 31.765678  | 0.640155  | 30.000000  | 31.002700  | 32.000000  | 32.000000  | 33.000000  |
| anomaly             | 3367.0 | 0.338580   | 0.473297  | 0.000000   | 0.000000   | 0.000000   | 1.000000   | 1.000000   |
| changepoint         | 3367.0 | 0.003267   | 0.057073  | 0.000000   | 0.000000   | 0.000000   | 0.000000   | 1.000000   |

上記を見ると変数は 10 あり目的変数が anomaly であるため、説明変数は 9 つである。そして、mean が最大で 231 に対して最小 0.003 と、変数間のスケール差が大きいことがわかる。

次に、相関ヒートマップを作成した。




図 1. 相関ヒートマップ

上記の図を見ると、anomaly と VolumeFlowRateRMS の相関が負の方向に 0.5 となっており強い関係が存在すると評価できる。

次に、上記で可視化したデータを用いて、モデリング・評価した結果を以下に示す。

#### ① XGBoost

XGBoost を用いて、分析した結果を以下に示す。

##### 1. 変数重要度

はじめに変数重要度を以下に示す。




図 2. XGBoost モデルの変数重要度

上記の図を見ると、Volume Flow Rate RMS が著しく高く、他の変数の重要度が低く推移していることがわかる。

2. SHAP 値

次に、SHAP 値の図を以下に示す。




図 3. SHAP Summary Plot(beeswarm)




図 4. SHAP Summary Plot(bar)




図 5. SHAP waterfall

## ② RandomForest

RandomForest を用いて、分析した結果を以下に示す。

### 1. 変数重要度

はじめに、Random Forest の変数重要度を以下に示す。




図 6. Random Forest モデルの変数重要度

### 2. SHAP 値

次に、SHAP 値の図を以下に示す。




図 7. SHAP Summary Plot(beeswarm)




図 8. SHAP summary plot (bar)




図 9. SHAP waterfall

上記の変数重要度, SHAP の図を見ると、以下のことがわかる。

1. 変数重要度では、Volume Flow Rate RMS と Temperature、Thermocouple が順に高くなっており、Temperature、Thermocouple の推移が XGBoost と比較して相対的に高くなっている。
2. SHAP beeswarm は、XGBoost と同様の形状をしているがスケールが異なっている。
3. SHAP Summary Plot(bar)は、XGBoost と同様の順に並んでいる。
4. SHAP Summary Plot(beeswarm) について、Accelerometer2RMS のみ XGBoost のものと逆になっていた。ただし、SHAP 値は  $f(x) - E[f(X)]$  に基づいて計算されるため、モデルの出力空間や決定構造が異なる場合、同一特徴量であっても寄与の方向が異なって見える場合があるため、妥当であると評価する。

### ③ SVM

最後に、SVM のモデルを構築し、変数重要度と SHAP 値を求めた。

#### 1. 変数重要度




図 10. SVM における変数重要度

上記より、わかることを以下に箇条に構造化して示す。

- (ア) 変数重要度の順位は、XGBoost と RandomForest の両方と同一であった。
- (イ) スケールは、RandomForest のものと近い。
- (ウ) 変数重要度の形状は、RandomForest と類似しており、上位三つの変数が高く他の変数が低く推移していた。

#### 2. SHAP 値

次に SHAP 値について可視化した図を以下に示す。




図 11. SHAP Summary Plot(beeswarm)




図 12. SHAP summary plot (bar)




図 13. SHAP waterfall

上記の変数重要度, SHAP の図を見ると、以下のことがわかる。

- (ア) SHAP Summary Plot (beeswarm) より、Volume Flow Rate RMS は広い SHAP 値の分布を示しており、個々のサンプルにおける予測への影響が大きく変動していることが分かる。そのため、流量の状態が予測結果に与える影響は一様ではなく、運転状況に応じて異なる役割を果たしている可能性が示唆される。
- (イ) Thermocouple および Temperature は、特徴量の値の大小と SHAP 値の符号に明確な対応関係が見られ、比較的単調な影響構造を持つ特徴量であると考えられる。
- (ウ) beeswarm において、特定の特徵量では高い値と低い値のサンプルが異なる SHAP 値領域に分離して分布しており、特徴量の値そのものが予測方向を左右している様子が確認できる。



(エ) waterfall 図から、単一サンプルの予測値は複数の特徴量の正負の寄与が段階的に積み上がることで形成されていることが分かる。

#### (エ) 考察

本課題では、SKAB データを対象として XGBoost、RandomForest、SVM の 3 種類のモデルを構築し、変数重要度および SHAP 値を用いて予測に寄与する特徴量の違いを比較した。分析の結果、各モデルで重要と判断される特徴量には共通点が見られる一方で、その寄与の評価方法や解釈にはモデル固有の差異が存在することが確認された。

まず XGBoost における変数重要度は、損失関数の減少量に基づいて定義される。XGBoost は以下の目的関数を最小化する勾配ブースティングモデルである。

$$\mathcal{L} = \sum_i l(y_i, \hat{y}_i) + \sum_t \Omega(f_t)$$

ここで、各分岐における特徴量の重要度は、一次・二次勾配を用いた Gain によって評価される。本分析では Volume Flow Rate RMS が極めて高い重要度を示しており、これは当該特徴量が損失関数を大きく減少させる分岐を頻繁に生み出していることを意味する。一方で、Temperature や Thermocouple の重要度は相対的に低く、XGBoost が少数の特徴量に寄与を集中させる傾向を持つことが反映された結果であると考えられる。

これに対し RandomForest の変数重要度は、不純度減少量の総和として定義される。例えば Gini 不純度を用いる場合、特徴量 $x_j$ の重要度は次式で表される。

$$Imp(x_j) = \sum_{m \in x_j} \frac{N_m}{N} [I(m) - I(m_L) - I(m_R)]$$

RandomForest では多数の決定木による分散的な学習が行われるため、Temperature や Thermocouple といった複数の特徴量が比較的均等に予測へ寄与する傾向が見られた。この結果、XGBoost と比較して温度系変数の相対的重要度が高く評価されたと解釈できる。特に、本分析で用いたデータは、図 1 の相関ヒートマップを見ると、強い負の相関があることがわかる。そのため、相関の高い説明変数が同程度の重要度を逆方向に有していたと考察できる。

次に SHAP 値を用いた解析では、モデルに依存しない「予測への限界貢献」という共通の尺度で特徴量を評価できる点が特徴である。SHAP 値は、以下の

Shapley 値に基づいて定義される。

$$\varphi_j = \sum_{S \subseteq F \setminus \{j\}} |S|! \frac{(M - |S| - 1)!}{M!} [f(S \cup \{j\}) - f(S)]$$

この定義より、SHAP 値は平均との差

$$\sum_j \varphi_j = f(x) - E[f(X)]$$

を満たすように分解される。

本分析では、SHAP summary plot (bar) における重要度順位が XGBoost、RandomForest、SVM の間で一致しており、VolumeFlowRateRMS、Temperature、Thermocouple がいずれのモデルにおいても予測に本質的に寄与していることが確認された。この結果は、モデル固有の変数重要度とは異なり、SHAP が共通の評価基準を提供していることを示している。

一方で、SHAP summary plot (beeswarm) では、特に Accelerometer2RMS においてモデル間で寄与の方向性が異なる傾向が見られた。これは SHAP 値が

$$f(x) - E[f(X)]$$

という「基準値との差」に基づいて計算されるため、各モデルの出力空間や決定構造の違いが符号に反映された結果であると考えられる。また、RandomForest のような木構造モデルでは特徴量間の相互作用が条件付きで学習されるため、補助的な特徴量が文脈依存的に異なる役割を持つ可能性が示唆される。

SVM に対する SHAP 解析では、寄与の分布が比較的滑らかであり、流量が予測を正常側へ、温度が異常側へ押し上げるといった単調な関係が明瞭に確認された。これは、SVM が以下の最適化問題に基づき、決定境界のマージン最大化を目的とするモデルであることに起因すると考えられる。

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_i \varepsilon_i$$

以上より、変数重要度は各モデルの最適化基準や学習構造を反映するためモデル間で差が生じる一方、SHAP 値は予測への限界貢献という共通の数理的定義に基

づくため、モデルを横断した比較が可能であることが示された。本課題を通じて、異なる予測モデルを比較する際には、性能指標だけでなく、SHAP のような説明手法を併用することが、モデルの挙動理解および解釈の一貫性を確保する上で重要であると考察する。

### 3. 課題 2

#### (ア) 課題概要

自分の興味のあるデータ（対象は何でも良いが回帰の問題をおすすめする：SHAP バージョンによるトラブルを避けるため）について今回と同様の RandomForest や SHAP 値による解析を行い、対象のデータの予測に効く変数がどのようなものか、またそこからどのようなことが考察できるのか（どのような現象が発生しているか？など）について考察を行え。

#### (イ) 分析方針

本課題では、以下のデータを利用した。

##### 1. データ概要

中央、地方競馬のレース結果データで、各レースの一位をクラス 0~3 位以内をクラス 1, それ以外をクラス 2 とするデータ。データの詳細や基本統計量等については、GitHub のリポジトリに記載することとした。

##### 2. データ取得元

NetKeiba(<https://www.netkeiba.com/>)

##### 3. データ取得方法

本分析では上記ページをスクレイピングすることにより取得した。スクレイピングコードは、付録の項に url リンクを掲載した。以下にスクレイピングの方針を示す。

##### 1. URL 構造を確認

当該サイトのレース結果をまとめたページは以下のような URL 構造となっている。

(ア) レース開催日のカレンダーページ

<https://race.netkeiba.com/top/calendar.html?year={年 4 桁}&month={月}>

(イ) 開催レース一覧ページ

[https://race.netkeiba.com/top/race\\_list.html?kaisai\\_date={日付 8 桁}](https://race.netkeiba.com/top/race_list.html?kaisai_date={日付 8 桁})

(ウ) レース結果ページ

[https://race.netkeiba.com/race/result.html?race\\_id={レース id12 桁}](https://race.netkeiba.com/race/result.html?race_id={レース id12 桁})

上記ページを順に WebDriver と Selenium を用いてスクレイピングすることにより、網羅的に収集する。

- BeautifulSoup でテーブルを取得し Pandas で加工  
BeautifulSoup を持ちいてテーブルデータ(html)を取得し、Pandas の DataFrame 型に変換し、加工する。
- 変数変換(特徴量エンジニアリング)  
レース id や騎手名などを除外する。

#### 4. データ対象期間とサンプリング期間

開始日: 2018 年 1 月

終了日: 2025 年 9 月

サンプリングレート: 0.05

※本対象期間のレース数が膨大であり、SVM での実行時間を考慮し当該サンプリングレートでのデータ標本を生成した。

モデリング方針を以下に示す。

#### 1. データの取得と加工

表形式のデータから、訓練データとテストデータに分割する。また int 型, float 型でない列については、分析データから除外する。

#### 2. XGBoost, RandomForest, SVM モデルを構築する

各モデルを構築する。

#### 3. 各モデルの SHAP 値や変数重要度を比較する

SVM の重要度は Permutation Importance で算出する。そして、RF は不純度減少、XGB は gain、SVM は Permutation であり定義が異なるため、順位中心に比較する

### (ウ) 分析結果

はじめにデータの概要を確認した。基本統計量を以下に示す。

表 2. 基本統計量

|              | count   | mean         | std          | min           | 25%           | 50%          | 75%          | max          |
|--------------|---------|--------------|--------------|---------------|---------------|--------------|--------------|--------------|
| wakuban      | 18661.0 | 4.766518e+00 | 2.271706e+00 | 1.000000e+00  | 3.000000e+00  | 5.000000e+00 | 7.000000e+00 | 8.000000e+00 |
| umaban       | 18661.0 | 7.792455e+00 | 4.434985e+00 | 1.000000e+00  | 4.000000e+00  | 8.000000e+00 | 1.100000e+01 | 1.800000e+01 |
| age          | 18661.0 | 3.631745e+00 | 1.344700e+00 | 2.000000e+00  | 3.000000e+00  | 3.000000e+00 | 4.000000e+00 | 1.200000e+01 |
| kinryo       | 18661.0 | 5.516317e+01 | 1.876922e+00 | 4.800000e+01  | 5.400000e+01  | 5.500000e+01 | 5.600000e+01 | 6.300000e+01 |
| agari        | 18661.0 | 3.640558e+01 | 4.680278e+00 | 1.290000e+01  | 3.530000e+01  | 3.680000e+01 | 3.850000e+01 | 7.160000e+01 |
| tansho       | 18661.0 | 6.884084e+01 | 1.020497e+02 | 1.100000e+00  | 8.100000e+00  | 2.490000e+01 | 8.290000e+01 | 8.542000e+02 |
| ninki        | 18661.0 | 7.759070e+00 | 4.420082e+00 | 1.000000e+00  | 4.000000e+00  | 7.000000e+00 | 1.100000e+01 | 1.800000e+01 |
| bataiju      | 18661.0 | 4.707642e+02 | 3.032595e+01 | 3.300000e+02  | 4.500000e+02  | 4.700000e+02 | 4.920000e+02 | 6.060000e+02 |
| bataiju_sa   | 18661.0 | 3.768823e-01 | 6.228682e+00 | -3.900000e+01 | -3.000000e+00 | 0.000000e+00 | 4.000000e+00 | 6.600000e+01 |
| race_id      | 18661.0 | 2.021418e+11 | 2.282114e+08 | 2.018010e+11  | 2.019090e+11  | 2.021071e+11 | 2.023091e+11 | 2.025100e+11 |
| time_seconds | 18661.0 | 1.018861e+02 | 2.964180e+01 | 5.420000e+01  | 8.000000e+01  | 9.850000e+01 | 1.167000e+02 | 2.899000e+02 |
| rank_class   | 18661.0 | 1.712502e+00 | 5.906821e-01 | 0.000000e+00  | 2.000000e+00  | 2.000000e+00 | 2.000000e+00 | 2.000000e+00 |

※各変数の説明は GitHub リポジトリの方に記載することとした。

上記の表を見ると、平均、分散に大きな差がなく標準化等せずにモデルで利用できると言える。

次に、モデリングの評価結果をモデルごとに示す。

#### ① XGBoost

モデルを構築した後に、変数重要度, SHAP 値の可視化を実施した。

##### 1. 変数重要度

変数重要度を以下に示す。




図 14. XGBoost の変数重要度

図 14 より、tansho（単勝オッズ）が最も高い重要度を示していることが分かる。次いで ninki（人気）、agari（上がり）の順に重要度が高く、これらの変数が上位に位置している。

一方で、time\_seconds、age、race\_id は中程度の重要度を示しており、上位の変数と比較すると重要度は低い。さらに、bataiju、bataiju\_sa、umaban、wakuban、kinryo の重要度は相対的に低く、下位に位置している。以上より、XGBoost の変数重要度の図から、変数ごとの重要度には明確な差があり、少数の変数が高い重要度を示していることが確認できる。

## 2. SHAP 値

次に、SHAP 値を可視化した図を以下に示す。




図 15. SHAP Summary Plot(beeswarm)




図 16. SHAP summary plot (bar)




図 17. SHAP waterfall

図 15 を見ると、tansho が最も広い SHAP 値の分布を示しており、予測への影響の大きさが他の変数と比べて大きいことが分かる。次いで agari、time\_seconds が比較的広い分布を持ち、これらの変数も予測に対して一定の影響を与えていることが確認できる。一方で、age、ninki、race\_id、bataiju、umaban、bataiju\_sa は SHAP 値が 0 付近に集中しており、影響の大きさは相対的に小さい。

図 16 より、平均絶対 SHAP 値は tansho が最も高く、agari、time\_seconds、age、ninki の順に小さくなっていることが分かる。また、変数間で平均絶対 SHAP 値に明確な差があり、上位の変数と下位の変数の影響度が分かれていることが確認できる。

図 17 より、単一サンプルの予測値は、複数の変数の SHAP 値が加算されることで形成されていることが分かる。このサンプルでは、time\_seconds、agari、tansho、bataiju、age などが順に寄与しており、各変数が正または負の SHAP 値を持っていることが確認できる。

以上より、SHAP の可視化結果から、変数ごとに予測への影響の大きさや分布に違いがあること、および予測値が複数の変数の寄与の合計として表現されていることが読み取れる。

## ② RandomForest

モデルを構築した後に、変数重要度, SHAP 値の可視化を実施した。

### 1. 変数重要度

変数重要度を以下に示す。




図 18. RandomForest の変数重要度

図 18 の変数重要度より、tansho が最も高い重要度を示しており、他の変数と比べて突出して大きい値を持っていることが分かる。

次いで ninki が高い重要度を示しており、これら 2 変数が上位に位置している。agari は tansho、ninki に次ぐ重要度を示しているが、上位 2 変数との差は大きい。一方で、age、bataiju、time\_seconds、umaban は重要度が小さく、上位の変数と比べて寄与は限定的である。さらに、bataiju\_sa、kinryo、race\_id、wakuban は重要度がほぼ 0 に近く、他の変数と比較して極めて小さい値を示している。

以上より、RandomForest における変数重要度は、一部の変数（tansho、ninki）に強く集中しており、それ以外の多くの変数は相対的に低い重要度を示していることが読み取れる。



## 2. SHAP 値

次に、SHAP 値を可視化した図を以下に示す。




図 19. SHAP Summary Plot(beeswarm)




図 20. SHAP summary plot (bar)




図 21. SHAP waterfall

図 19 の SHAP Summary Plot (beeswarm) より、tansho、ninki、agari は他の変数と比較して SHAP 値の分布幅が大きく、正の方向に広く分布していることが確認できる。一方で、age、bataiju、time\_seconds、umaban、bataiju\_sa、kinryo は SHAP 値が 0 付近に集中しており、分布の広がり小さい。

また、beeswarm において tansho、ninki は高い特徴量値（赤色）と低い特徴量値（青色）で SHAP 値の位置に差が見られ、他の変数と比べて分布の非対称性が確認できる。

図 20 の SHAP summary plot (bar) より、tansho と ninki が最も大きな平均絶対 SHAP 値を示しており、上位に位置している。次いで agari が続き、それ以外の変数は平均絶対 SHAP 値が小さく、0 に近い値を示している。

図 21 の SHAP waterfall より、単一サンプルの予測値は、tansho、ninki による負の寄与が大きく、その後に agari、age、bataiju、time\_seconds などの小さな正負の寄与が加算されることで形成されることが分かる。

以上より、RandomForest の SHAP 可視化結果から、少数の変数が予測値に対して相対的に大きな影響を持ち、多くの変数は影響が小さいこと、および予測値が各変数の SHAP 値の和として表現されていることが確認できる。

### ③ SVM

モデルを構築した後に、変数重要度, SHAP 値の可視化を実施した。

#### 1. 変数重要度

変数重要度を以下に示す。




図 22. 変数重要度

図 22 の変数重要度より、ninki、agari、tansho が他の変数と比較して高い重要度を示しており、上位に位置していることが分かる。

これら 3 変数は、Permutation Importance の値が相対的に大きい。次いで、time\_seconds、kinryo、umaban、wakuban が中程度の重要度を示しており、上位 3 変数と比べると重要度は小さいものの、一定の寄与が確認できる。一方で、age、bataiju、bataiju\_sa、race\_id は重要度が非常に小さく、0 付近、あるいは負の値を示している変数も存在する。以上より、SVM における変数重要度は、一部の変数に集中して高く、その他の変数は相対的に低い値を示していることが読み取れる。

## 2. SHAP 値

次に、SHAP 値を可視化したものを示す。




図 23. SHAP Summary Plot(beeswarm)




図 24. SHAP Summary plot (bar)




図 25. SHAP waterfall

SHAP Summary Plot (beeswarm) より、agari、ninki、tansho は他の変数と比較して SHAP 値の分布幅が大きく、正負の両方向に広がっていることが確認できる。一方で、time\_seconds、age、wakuban、umaban、kinryo、bataiju\_sa は SHAP 値が 0 付近に集中しており、分布の広がりはいくらか小さい。

SHAP summary plot (bar) より、agari、ninki、tansho が平均絶対 SHAP 値の上位に位置しており、他の変数と比べて相対的に大きな値を示していることが分かる。これに続いて time\_seconds、age が中程度の値を示し、wakuban、umaban、kinryo、bataiju\_sa は下位に位置している。

SHAP waterfall より、単一サンプルに対する予測値は、複数の変数の SHAP 値が加算されることで形成されていることが確認できる。このサンプルでは、ninki、agari、tansho などが比較的大きな寄与を持ち、それ以外の変数は小さな正または負の寄与を示している。

以上より、SVM の SHAP 可視化結果から、変数ごとに予測への寄与の大きさに差があり、予測値が各変数の SHAP 値の和として表現されていることが読み取れる。

## (エ) 考察

本課題では、競馬レース結果データを対象として 課題 1 と同様に XGBoost、RandomForest、SVM の 3 種類のモデルを構築し、変数重要度および SHAP 値を用いて、予測に寄与する特徴量とその影響の仕方を分析した。分析の結果、いずれのモデルにおいても tansho (単勝オッズ)、ninki (人気)、agari (上がり) が予測に強く関与していることが確認された。

まず、変数重要度の観点から見ると、XGBoost および RandomForest では tansho が最も高い重要度を示し、次いで ninki、agari が続くという共通した傾向が見られた。これは、これらの変数がモデルの分岐や不純度減少に頻繁に利用されていることを示している。一方、SVM においても Permutation Importance により同様の順位関係が得られており、重要度の定義が異なるにもかかわらず、上位変数の順位が一致している点は、どのモデルにおいても当該変数の重要度が高かったからであると考察する。

SHAP 値を用いた解析では、モデル間で共通する特徴量の寄与構造がより明確に示された。SHAP 値は Shapley 値に基づき、以下の性質を満たすよう定義される。

$$f(x) = E[f(X)] + \sum_{i=1}^M \varphi_i$$

ここで $\varphi_i$ は特微量  $i$  の SHAP 値であり、平均との差に対する限界貢献を表す。この定義により、モデルの種類に依存せず、各特微量の寄与を同一の尺度で比較することが可能となる。

SHAP summary plot (bar) を見ると、XGBoost、RandomForest、SVM のいずれにおいても tansho、ninki、agari が上位に位置しており、これらの変数が予測に対して本質的な役割を果たしていることが確認された。これは、モデル固有の変数重要度では異なって見える寄与が、SHAP によって統一的に評価されていることを示している。

一方、SHAP summary plot (beeswarm) では、変数ごとの影響の仕方に違いが見られた。特に tansho や ninki では SHAP 値の分布幅が大きく、特微量の値に応じて予測への影響が大きく変動していることが確認できる。これは、これらの変数が予測値を単調に押し上げる・押し下げるだけでなく、状況依存的に異なる役割を果たしていることを示唆している。また、RandomForest においては一部の変数で SHAP 値の符号が他モデルと異なる傾向が見られた。SHAP 値は

$$\varphi_i = E[f(X) | X_i = x_i] - E[f(X)]$$

に基づいて算出されるため、モデルの出力空間や条件分岐構造の違いが寄与の方向性に反映される。このことから、符号の違い自体は異常ではなく、モデルの決定構造の違いが SHAP 値に表現された結果であると考えられる。

SVM における SHAP 解析では、寄与の分布が比較的滑らかであり、主要な特微量が決定境界に対して安定した影響を与えている様子が確認された。これは、SVM が以下の最適化問題に基づき、マージン最大化を目的とするモデルであることと整合的である。

$$\min_{w,b} \|w\|^2 + C \sum_i \varepsilon_i$$

以上の結果から、競馬レース結果データにおいては、市場情報（単勝オッズや人気）および走行性能指標（上がり）が予測に対して支配的な役割を果たしていることが示された。また、SHAP を用いることで、異なるモデル間でも予測への寄与を共通の枠組みで比較できることが確認された。本課題を通じて、複雑な予測モデルを用いる場合であっても、SHAP による説明を併用することで、モデルの挙動や背後にある現象を定量的に理解できることが示された。

#### 4. 参考文献

- (ア) Rabi Kumar Singh, Kaggle: Feature Importance,  
(<https://www.kaggle.com/code/jurk06/feature-importance>),  
2026/01/09 閲覧。
- (イ) Lundberg, S. M., Erion, G., & Lee, S.-I. (2020)  
「決定木アンサンブルにおける一貫した特徴量寄与の算出」  
arXiv preprint arXiv:1802.03888, 2026/01/09 閲覧。
- (ウ) SHAP 開発チーム  
「SHAP (SHapley Additive exPlanations) 公式ドキュメント」  
(<https://shap.readthedocs.io/en/latest/>), 2026/01/09 閲覧。
- (エ) scikit-learn 開発チーム  
「サポートベクターマシン (SVM)」  
(<https://scikit-learn.org/stable/modules/svm.html>), 2026/01/09 閲覧。

#### 5. 付録

- (ア) 本分析で利用した GitHub レポジトリ  
(<https://github.com/yut0takagi/ass-production-management/tree/main>)
- (イ) 課題 1 利用したデータ元  
(<https://github.com/waico/SKAB/tree/master/data/valve1>)
- (ウ) 課題 2 データ収集で利用したスクレイピングコード等 GitHub リポジトリ  
(<https://github.com/yut0takagi/horse-race-prediction>)